(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121658673 A
(43)申请公布日 2026.03.13

(21)申请号 202511834070.1

(22)申请日 2025.12.05

(71)申请人 上海科世达-华阳汽车电器有限公司
地址 201814 上海市嘉定区安亭镇园高路77号
申请人 科世达(上海)机电有限公司
科世达(上海)管理有限公司

(72)发明人 吕崇明 程晖 蒋卓轩 李衍朋

(74)专利代理机构 北京信远达知识产权代理有限公司 11304
专利代理师 曹心禹

(51)Int.Cl.
G06F 16/38(2019.01)
G06F 16/36(2019.01)
G06N 3/084(2023.01)
G06N 5/022(2023.01)
G06N 5/04(2023.01)

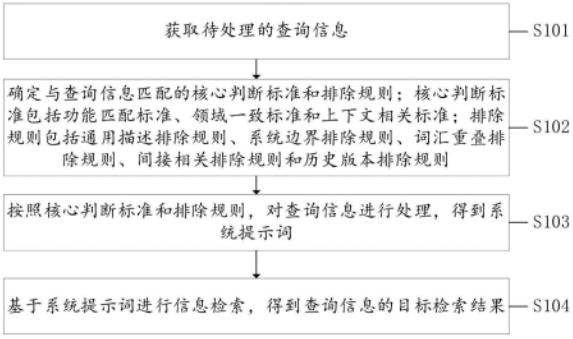
权利要求书2页 说明书15页 附图7页

(54)发明名称

一种信息检索方法、系统、设备及计算机可读存储介质

(57)摘要

本申请公开了一种信息检索方法、系统、设备及计算机可读存储介质,涉及智能检索技术领域,获取待处理的查询信息;确定与查询信息匹配的核心判断标准和排除规则;按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词;基于系统提示词进行信息检索,得到查询信息的目标检索结果;其中,核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。本申请可以得到与查新信息功能匹配、领域一致、上下文关联且不含通用描述、跨系统边界、不含重叠词、直接关联且与最新版本一致的系统提示词,提高了检索精度。



CN 121658673 A

中国知网 https://www.cnki.net

1.一种信息检索方法,其特征在于,包括:

获取待处理的查询信息;

确定与所述查询信息匹配的核心判断标准和排除规则;

按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词;

基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果;

其中,所述核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;所述排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

2.根据权利要求1所述的方法,其特征在于,所述按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词,包括:

对所述查询信息进行扁平化处理,得到所述查询信息对应的原子条目;

对所述原子条目进行分组,得到条目分组结果;

按照所述核心判断标准和所述排除规则,批量对所述条目分组结果进行处理,得到系统提示词。

3.根据权利要求2所述的方法,其特征在于,所述对所述查询信息进行扁平化处理,得到所述查询信息对应的原子条目,包括:

生成所述查询信息的上下文信息;

对所述查询信息进行处理,得到初始信息;

对所述初始信息进行证据抽取和索引增强,得到候选信息;

对所述候选信息进行特征提取,得到特征数据;

对所述特征数据进行去重与弱相似合并,得到原子条目;

基于所述上下文信息,生成所述原子条目的元数据。

4.根据权利要求3所述的方法,其特征在于,所述对所述查询信息进行处理,得到初始信息,包括:

对所述查询信息中的段落进行去噪、空白规范、断行合并、列表合并、单位标准化和术语标准化,得到自然段处理结果;

对所述查询信息中的表格和图片进行表头键值化和文本提取,得到结构化占位条目和位置指针;

按照语义边界,将所述查询信息中跨段落的语句切分为最小语义单元,生成所述最小语义单元与对应段落间的父子关系和顺序索引;

将所述自然段处理结果、所述结构化占位条目、所述位置指针、所述最小语义单元、所述父子关系和所述顺序索引,作为初始信息。

5.根据权利要求4所述的方法,其特征在于,所述基于所述上下文信息,生成所述原子条目的元数据,包括:

基于所述上下文信息,生成所述原子条目的元数据,所述元数据包括源文件、段落定位结果、主题候选结果、证据片段摘要、长度和质量评分。

6.根据权利要求5所述的方法,其特征在于,所述基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果,包括:

获取缓存的预检索结果;

中国知网 https://www.cnki.net

检测所述系统提示词与所述预检索结果是否匹配;

响应于所述系统提示词与所述预检索结果匹配,则从所述预检索结果中提取出所述查询信息的目标检索结果。

7.根据权利要求6所述的方法,其特征在于,所述检测所述系统提示词与所述预检索结果是否匹配之后,还包括:

响应于所述系统提示词与所述预检索结果不匹配,则按照统一的语义模板对所述系统提示词进行对齐和约束,得到语义处理结果;

调用训练好的大语言模型对所述语义处理结果进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果;

对所述初始检索结果进行一致性校验和置信度聚合,得到所述查询信息的目标检索结果。

8.一种信息检索系统,其特征在于,包括:

查询信息获取模块,用于获取待处理的查询信息;

筛选条件确定模块,用于确定与所述查询信息匹配的核心判断标准和排除规则;

查询处理模块,用于按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词;

检索模块,用于基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果;

其中,所述核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;所述排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

9.一种电子设备,其特征在于,包括:

存储器,用于存储计算机程序;

处理器,用于执行所述计算机程序时实现如权利要求1至7任一项所述信息检索方法的步骤。

10.一种计算机可读存储介质,其特征在于,所述计算机可读存储介质中存储有计算机程序,所述计算机程序被处理器执行时实现如权利要求1至7任一项所述信息检索方法的步骤。

中国知网 https://www.cnki.net

一种信息检索方法、系统、设备及计算机可读存储介质

技术领域

[0001] 本申请涉及智能检索技术领域,更具体地说,涉及一种信息检索方法、系统、设备及计算机可读存储介质。

背景技术

[0002] 随着深度学习技术的发展,在智能问答等过程中,可以基于向量相似度按用户需求来进行信息检索。也即将用户输入的文本转换为高维向量表示,通过计算向量间的余弦相似度等指标来判断文本相关性。

[0003] 虽然向量相似度检索在语义理解方面有所改进,但仍存在诸多不足。例如向量表示能力有限,难以捕捉复杂的语义关系和上下文信息,此外,向量检索对上下文信息的理解不足,无法进行深度的语义推理和判断。当查询涉及复杂的技术逻辑关系时,单纯的向量相似度计算往往无法准确判断相关性。

[0004] 综上所述,如何提高检索精度是目前本领域技术人员亟待解决的问题。

发明内容

[0005] 本申请的目的是提供一种信息检索方法,其能在一定程度上解决如何提高检索精度的技术问题。本申请还提供了一种信息检索系统、电子设备及计算机可读存储介质。

[0006] 为了实现上述目的,本申请提供如下技术方案:

[0007] 一种信息检索方法,包括:

[0008] 获取待处理的查询信息;

[0009] 确定与所述查询信息匹配的核心判断标准和排除规则;

[0010] 按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词;

[0011] 基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果;

[0012] 其中,所述核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;所述排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

[0013] 优选的,所述按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词,包括:

[0014] 对所述查询信息进行扁平化处理,得到所述查询信息对应的原子条目;

[0015] 对所述原子条目进行分组,得到条目分组结果;

[0016] 按照所述核心判断标准和所述排除规则,批量对所述条目分组结果进行处理,得到系统提示词。

[0017] 优选的,所述对所述查询信息进行扁平化处理,得到所述查询信息对应的原子条目,包括:

[0018] 生成所述查询信息的上下文信息;

中国知网 https://www.cnki.net

[0019] 对所述查询信息进行处理,得到初始信息;

[0020] 对所述初始信息进行证据抽取和索引增强,得到候选信息;

[0021] 对所述候选信息进行特征提取,得到特征数据;

[0022] 对所述特征数据进行去重与弱相似合并,得到原子条目;

[0023] 基于所述上下文信息,生成所述原子条目的元数据。

[0024] 优选的,所述对所述查询信息进行处理,得到初始信息,包括:

[0025] 对所述查询信息中的段落进行去噪、空白规范、断行合并、列表合并、单位标准化和术语标准化,得到自然段处理结果;

[0026] 对所述查询信息中的表格和图片进行表头键值化和文本提取,得到结构化占位条目和位置指针;

[0027] 按照语义边界,将所述查询信息中跨段落的语句切分为最小语义单元,生成所述最小语义单元与对应段落间的父子关系和顺序索引;

[0028] 将所述自然段处理结果、所述结构化占位条目、所述位置指针、所述最小语义单元、所述父子关系和所述顺序索引,作为初始信息。

[0029] 优选的,所述基于所述上下文信息,生成所述原子条目的元数据,包括:

[0030] 基于所述上下文信息,生成所述原子条目的元数据,所述元数据包括源文件、段落定位结果、主题候选结果、证据片段摘要、长度和质量评分。

[0031] 优选的,所述基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果,包括:

[0032] 获取缓存的预检索结果;

[0033] 检测所述系统提示词与所述预检索结果是否匹配;

[0034] 响应于所述系统提示词与所述预检索结果匹配,则从所述预检索结果中提取出所述查询信息的目标检索结果。

[0035] 优选的,所述检测所述系统提示词与所述预检索结果是否匹配之后,还包括:

[0036] 响应于所述系统提示词与所述预检索结果不匹配,则按照统一的语义模板对所述系统提示词进行对齐和约束,得到语义处理结果;

[0037] 调用训练好的大语言模型对所述语义处理结果进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果;

[0038] 对所述初始检索结果进行一致性校验和置信度聚合,得到所述查询信息的目标检索结果。

[0039] 一种信息检索系统,包括:

[0040] 查询信息获取模块,用于获取待处理的查询信息;

[0041] 筛选条件确定模块,用于确定与所述查询信息匹配的核心判断标准和排除规则;

[0042] 查询处理模块,用于按照所述核心判断标准和所述排除规则,对所述查询信息进行处理,得到系统提示词;

[0043] 检索模块,用于基于所述系统提示词进行信息检索,得到所述查询信息的目标检索结果;

[0044] 其中,所述核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;所述排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除

中国知网 https://www.cnki.net

规则和历史版本排除规则。

[0045] 一种电子设备,包括:

[0046] 存储器,用于存储计算机程序;

[0047] 处理器,用于执行所述计算机程序时实现如上任一所述信息检索方法的步骤。

[0048] 一种计算机可读存储介质,所述计算机可读存储介质中存储有计算机程序,所述计算机程序被处理器执行时实现如上任一所述信息检索方法的步骤。

[0049] 本申请提供的一种信息检索方法,获取待处理的查询信息;确定与查询信息匹配的核心判断标准和排除规则;按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词;基于系统提示词进行信息检索,得到查询信息的目标检索结果;其中,核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。本申请中,在获取查询信息之后,需按照功能匹配标准、领域一致标准和上下文相关标准对查询信息进行处理,且需按照通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则对查询信息进行处理,从而可以得到与查新信息功能匹配、领域一致、上下文关联且不含通用描述、跨系统边界、不含重叠词、直接关联且与最新版本一致的系统提示词,提高了信息检索过程中的语义理解能力,能够准确理解查询的真实意图和需求,增强了领域适应性,降低了检索误报率,提高了检索精度。本申请提供的一种信息检索系统、电子设备及计算机可读存储介质也解决了相应技术问题。

附图说明

[0050] 为了更清楚地说明本申请实施例或现有技术中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是本申请的实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据提供的附图获得其他的附图。

[0051] 图1为本申请实施例提供的一种信息检索方法的流程图;

[0052] 图2为基于条目进行信息检索的流程图;

[0053] 图3为批量处理优化机制图;

[0054] 图4为基于预检索和全量检索进行信息检索的流程图;

[0055] 图5为预检索缓存的架构图;

[0056] 图6为进行信息检索的系统整体架构图;

[0057] 图7为智能相关性判断流程图;

[0058] 图8为本申请实施例提供的一种信息检索系统的结构示意图;

[0059] 图9为本申请实施例提供的一种电子设备的结构示意图;

[0060] 图10为本申请实施例提供的一种电子设备的另一结构示意图。

具体实施方式

[0061] 下面将结合本申请实施例中的附图,对本申请实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本申请一部分实施例,而不是全部的实施例。基于本申请中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他

中国知网 https://www.cnki.net

实施例,都属于本申请保护的范围。

[0062] 随着深度学习技术的发展,在智能问答等过程中,比如在汽车行业、制造业、软件工程等复杂技术领域的系统需求分析、文档管理和知识检索应用场景中,需进行相应的信息检索。

[0063] 传统的检索主要依赖于关键词匹配技术,包括TF-IDF(词频-逆文档频率)算法、BM25算法等。这些技术通过计算查询词与文档中词汇的匹配程度来确定相关性。例如,当用户查询“Park Switch唤醒功能”时,系统会在需求文档中搜索包含“Park”、“Switch”、“唤醒”等关键词的条目。然而,传统关键词检索技术存在显著的局限性。首先,无法理解语义含义,仅进行字面匹配,导致大量语义相关但用词不同的内容被遗漏。例如,文档中使用“停车开关”、“P档按钮”等不同表述描述同一功能时,传统检索方法无法识别其相关性。其次,关键词检索容易产生误报,当文档中包含查询关键词但语义无关时,仍会被错误地标记为相关。此外,传统方法无法处理同义词、近义词等语义相关但词汇不同的情况,如“唤醒”与“激活”、“开关”与“按钮”等专业术语的语义关联。

[0064] 随着向量相似度的检索技术的兴起,可以将文本转换为高维向量表示,通过计算向量间的余弦相似度等指标来判断文本相关性。例如,使用Word2Vec、GloVe等词向量模型,或者BERT、GPT等预训练语言模型将文本转换为向量表示。虽然向量相似度检索在语义理解方面有所改进,但仍存在诸多不足:向量表示能力有限,难以捕捉复杂的语义关系和上下文信息。例如,在汽车系统需求中,“E_CSW唤醒”和“电子控制开关激活”在语义上高度相关,但向量表示可能无法准确捕捉这种关联;此外,向量检索对上下文信息的理解不足,无法进行深度的语义推理和判断。当查询涉及复杂的技术逻辑关系时,单纯的向量相似度计算往往无法准确判断相关性。

[0065] 另一种常见的检索方法是基于预定义规则和模式匹配的技术。这类方法通过定义特定的规则模式来识别相关需求,例如定义正则表达式模式来匹配特定格式的需求描述。然而,基于规则匹配的检索技术存在明显的缺陷:规则维护成本高,扩展性差,难以适应新的查询模式和需求变化,当业务需求发生变化或出现新的技术术语时,需要人工更新规则,维护成本极高。此外,规则冲突处理复杂,当多个规则同时匹配时,难以确定优先级和最终结果。最重要的是,基于规则的方法缺乏智能化的适应性,无法从历史查询中学习和改进。

[0066] 根据相关技术文献,如《信息检索导论》(Christopher D.Manning等著)中提到的传统检索方法,以及《深度学习在信息检索中的应用》(ACM Computing Surveys,2019)中讨论的向量检索技术,现有检索方法在处理复杂语义查询时普遍存在精度不足的问题。在汽车行业需求分析领域,相关技术文献如《汽车电子系统需求工程》(SAE International,2020)指出,传统检索方法在处理专业术语和复杂技术关系时效果不佳。文献中提到,汽车系统需求文档通常包含大量专业术语、技术参数和复杂的逻辑关系,传统的基于关键词或向量的检索方法难以准确理解这些复杂的技术内容。

[0067] 综合分析后,现有检索方法存在以下核心问题:语义理解能力不足,无法准确理解用户查询的真实意图和需求;检索精度低,误报率高,相关度判断不准确;领域适应性差,难以处理专业领域的复杂术语和概念;缺乏智能判断能力,无法进行深度的语义分析和相关性判断;扩展性有限,难以适应新的查询模式和业务需求。这些技术缺陷严重制约了客户需求检索系统的实用性和准确性,特别是在汽车行业等对技术要求较高的领域,传统检索方

中国知网 https://www.cnki.net

法已无法满足日益复杂的业务需求。而本申请提供的信息检索方案可以提高检索精度。

[0068] 请参阅图1,图1为本申请实施例提供的一种信息检索方法的流程图。

[0069] 本申请实施例提供的一种信息检索方法,可以包括以下步骤:

[0070] 步骤S101:获取待处理的查询信息。

[0071] 实际应用中,可以先获取待处理的查询信息,比如通过llm_relevance_judgment()函数获取查询信息,查询信息可以由用户生成,也可以由人机交互设备生成等,且查询信息的类型可以根据应用场景灵活确定,比如查询信息可以为对车辆进行分析查询的信息,可以为对软件进行管理查询的信息等,本申请在此不做具体限定。

[0072] 步骤S102:确定与查询信息匹配的核心判断标准和排除规则;核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

[0073] 步骤S103:按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词。

[0074] 实际应用中,考虑到现有方案无法准确理解查询的真实意图和需求内容,才导致检索结果与检索期望存在较大偏差,所以为了提高检索精度,本申请需提高大语言模型的深度语义理解能力,以准确理解查询意图,包括复杂的技术术语、专业概念和上下文关系等,也即需确定与查询信息匹配的核心判断标准和排除规则,比如根据查询信息的类型确定与之匹配的核心判断标准和排除规则,且核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准,排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则;再按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词。为了便于理解,假设户查询信息为“Park Switch唤醒相关需求”,本申请可以准确理解这不仅仅是一个关键词匹配问题,而是涉及停车开关的唤醒机制、相关硬件输入、通信等多个技术层面的综合查询,并据此得到相关的系统提示词。

[0075] 需要说明的是,功能匹配标准用于限定系统提示词明确描述查询信息中的核心功能或特征,领域一致标准用于限定系统提示词属于查询信息涉及的技术领域、系统或组件,上下文相关标准用于限定系统提示词与查询信息所涉及的操作环境、使用场景相关;通用描述排除规则用于排除仅包含通用描述但无具体功能实现的提示词,系统边界排除规则用于排除属于其他系统或组件的与查询信息无关的提示词,词汇重叠排除规则用于排除与查询信息仅有词汇重叠但无实质关联的提示词,间接相关排除规则用于排序需经过多个步骤才能关联到查询信息所涉及问题的提示词,历史版本排除规则用于排除已废弃或过时的提示词。

[0076] 步骤S104:基于系统提示词进行信息检索,得到查询信息的目标检索结果。

[0077] 实际应用中,在得到系统提示词之后,便可以基于系统提示词进行信息检索,比如通过call_llm_api()函数调用预先训练好的大语言模型(Large Language Model,LLM)批量对系统提示词进行处理,得到查询信息的目标检索结果等,目标检索结果可以包括文件名、数据内容等。此外,还可以根据目标检索结果和查询信息计算检索覆盖率,根据检索覆盖率对信息检索过程进行调整,以保证信息检索效果。

[0078] 需要说明的是,可以根据具体的业务需求、技术条件、成本预算等因素对信息检索方式进行选取或组合,比如在对计算效率要求较高的场景下,可以采用基于向量数据库的

中国知网 https://www.cnki.net

混合检索方案,此方案通过构建需求文档的向量表示,结合向量相似度计算和传统关键词匹配,实现需求检索功能,具体技术实现包括:使用预训练语言模型将需求文档转换为高维向量表示,存储在向量数据库中,通过余弦相似度等算法计算查询向量与文档向量的相似性,结合TF-IDF等方法进行关键词匹配,综合两种方法的结果进行相关性判断。优势在于计算效率较高,向量检索速度较快,且技术实现相对简单,基于成熟的向量检索技术,开发和维护成本较低。

[0079] 在对检索精度要求较高的场景下,可以采用基于多模型融合的智能检索方案,此方案通过集成多种不同的检索模型,包括关键词匹配模型、向量相似度模型、语义理解模型等,通过模型融合算法综合各模型的结果,具体技术实现包括:训练多个专门的检索模型,每个模型负责不同的检索任务,设计模型融合算法,如加权平均、投票机制、学习排序等,通过机器学习方法优化各模型的权重和融合策略;该方案能够综合利用不同模型的优势,提高检索的鲁棒性和准确性,通过模型融合,可以降低单一模型的局限性,提高整体检索效果,技术实现具有较好的可扩展性,可以根据需要添加新的模型或调整融合策略。

[0080] 在大规模数据处理场景下,可以采用基于分布式架构的并行检索方案,此方案通过构建分布式检索架构,将检索任务分布到多个计算节点上并行处理,具体实现包括:设计分布式检索架构,包括主节点和多个工作节点,实现任务分发机制,将检索任务分配给不同的工作节点,通过消息队列等技术实现节点间的通信和协调,设计结果聚合算法,整合各节点的检索结果;该方案能够充分利用多核CPU和分布式计算资源,显著提升大规模数据的处理能力,通过并行处理,可以大幅缩短检索时间,提高系统吞吐量,且技术架构具有良好的可扩展性,可以根据数据规模和处理需求动态调整节点数量。

[0081] 在对可解释性要求较高的场景下,可以采用基于规则引擎的智能检索方案,通过构建领域知识库和规则引擎,实现智能化的需求检索功能。具体技术实现包括:构建汽车行业领域知识库,包含专业术语、技术概念、关系图谱等;设计规则引擎,定义各种检索规则和判断逻辑;实现推理机制,基于知识库和规则进行智能推理;设计规则更新机制,支持规则的动态添加和修改。该方案具有较好的可解释性,检索结果和判断过程相对透明,便于用户理解和验证,且规则引擎具有较好的可控性,可以根据业务需求灵活调整检索策略,技术实现相对稳定,不依赖于外部API服务,具有较好的可靠性。

[0082] 在对语义理解要求较高的场景下,可以采用基于深度学习的端到端检索方案,此方案通过训练端到端的深度学习模型,直接从用户查询和需求文档中学习相关性判断,具体实现包括:构建大规模的训练数据集,包含用户查询、需求文档、相关性标签等,设计端到端的神经网络架构,如BERT、GPT等预训练模型,实现模型训练和优化,通过反向传播算法优化模型参数,设计模型推理机制,实现快速的相关性判断。该方案能够端到端地学习复杂的语义关系,具有强大的表示学习能力,且通过大规模数据训练,模型可以学习到丰富的语义知识和领域特征,技术方案具有较好的泛化能力,可以适应不同的查询模式和文档类型。

[0083] 本申请提供的一种信息检索方法,获取待处理的查询信息;确定与查询信息匹配的核心判断标准和排除规则;按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词;基于系统提示词进行信息检索,得到查询信息的目标检索结果;其中,核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。本申

中国知网 https://www.cnki.net

请中,在获取查询信息之后,需按照功能匹配标准、领域一致标准和上下文相关标准对查询信息进行处理,且需按照通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则对查询信息进行处理,从而可以得到与查新信息功能匹配、领域一致、上下文关联且不含通用描述、跨系统边界、不含重叠词、直接关联且与最新版本一致的系统提示词,提高了信息检索过程中的语义理解能力,能够准确理解查询的真实意图和需求,增强了领域适应性,降低了检索误报率,提高了检索精度。此外,在效率方面,通过提高语义理解的准确性,可以将需求检索的准确率从传统方法的60-70%提升到90%以上,显著减少人工二次筛选的工作量,在成本控制方面,准确的语义理解可以减少因检索错误导致的重复工作和返工成本,预计可降低人工成本30-40%;在定量效果方面,可以将检索精度从传统方法的65%提升到92%以上,误报率从35%降低到8%以下;在定性效果方面,通过严格的排除规则和智能判断标准,能够有效过滤通用描述、系统边界不匹配、词汇重叠但无实质关联等误报情况,大幅提升检索结果的质量和可信度。

[0084] 在上述实施例的基础上,在处理大规模数据时,信息检索方案存在检索效率低下的问题,为了避免此种情况,请参阅图2,本申请实施例提供的一种信息检索方法,可以包括以下步骤:

[0085] 步骤S201:获取待处理的查询信息。

[0086] 步骤S202:确定与查询信息匹配的核心判断标准和排除规则;核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

[0087] 步骤S203:对查询信息进行扁平化处理,得到查询信息对应的原子条目。

[0088] 步骤S204:对原子条目进行分组,得到条目分组结果。

[0089] 步骤S205:按照核心判断标准和排除规则,批量对条目分组结果进行处理,得到系统提示词。

[0090] 实际应用中,在按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词的过程中,可以对查询信息进行扁平化处理,得到查询信息对应的原子条目,也即按文件/章节/段落/表格/图片等层级组织的内容,将查询信息统一转换为可独立判定的原子条目,以借助条目来细粒度的反映查询信息的特征;对原子条目进行分组,比如通过search_and_print()函数来按照BATCH_SIZE配置对原子条目进行分组,得到条目分组结果,分组过程中,可以优先将同主题、同器件(如ECU)或同文件的条目打包为一组以提升上下文一致性性等;按照核心判断标准和排除规则,批量对条目分组结果进行处理,比如调用llm_relevance_judgment()函数对条目分组结果进行处理,得到系统提示词,在此过程中,为了便于用户感知处理过程,还可以通过进度显示机制向用户展示处理进度,以使用户通过显示了解当前处理的批次号、总批次数、当前批次条目数等信息,如图3所示。如此一来,可以借助条目来细粒度的反映查询信息中的特征,并通过分组的方式来批量对条目分组结果进行并行处理,将处理效率提升3-5倍,将大语言模型API的调用次数减少80%以上,处理时间缩短60%以上,同时支持大规模数据的高效处理,以此提高系统提示词的生成效率,进而提高信息检索效率。

[0091] 在示例性实施例中,对查询信息进行扁平化处理,得到查询信息对应的原子条目的过程中,可以生成查询信息的上下文信息,上下文信息可以包括文件名、章节路径、REQ_

中国知网 https://www.cnki.net

ID、页码、坐标等;对查询信息进行处理,得到初始信息;对初始信息进行证据抽取和索引增强,比如按照信号名、报文ID、状态机术语、场景词与ECU实体等对初始信息进行证据抽取和索引增强,得到候选信息;对候选信息进行特征提取,得到特征数据,特征数据可以为倒排/向量特征等;对特征数据进行去重与弱相似合并,以保留最强证据版本并记录同义/别名,得到原子条目;基于上下文信息,生成原子条目的元数据。

[0092] 具体应用场景中,在对查询信息进行处理,得到初始信息的过程中,可以对查询信息中的段落进行去噪、空白规范、断行合并、列表合并、单位标准化和术语标准化,得到自然段处理结果;对查询信息中的表格和图片进行表头键值化和文本提取,文本提取包括OCR/标题提取等,得到结构化占位条目和位置指针,位置指针包括外链/坐标指针等;按照语义边界,将查询信息中跨段落的语句切分为最小语义单元,生成最小语义单元与对应段落间的父子关系和顺序索引;将自然段处理结果、结构化占位条目、位置指针、最小语义单元、父子关系和顺序索引,作为初始信息。

[0093] 具体应用场景中,在基于上下文信息,生成原子条目的元数据的过程中,可以基于上下文信息,生成原子条目的元数据,元数据包括源文件、段落定位结果、主题候选结果、证据片段摘要、长度和质量评分。

[0094] 步骤S206:基于系统提示词进行信息检索,得到查询信息的目标检索结果。

[0095] 在上述实施例的基础上,为了进一步提高检索效率,请参阅图4,本申请实施例提供的一种信息检索方法,可以包括以下步骤:

[0096] 步骤S301:获取待处理的查询信息。

[0097] 步骤S302:确定与查询信息匹配的核心判断标准和排除规则;核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则。

[0098] 步骤S303:按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词。

[0099] 步骤S304:获取缓存的预检索结果。

[0100] 步骤S305:检测系统提示词与预检索结果是否匹配;响应于系统提示词与预检索结果匹配,则执行步骤S306;响应于系统提示词与预检索结果不匹配,则执行步骤S307。

[0101] 步骤S306:从预检索结果中提取出查询信息的目标检索结果。

[0102] 步骤S307:按照统一的语义坐标系对系统提示词进行对齐和约束,得到语义模板。

[0103] 步骤S308:调用训练好的大语言模型对语义模板进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果。

[0104] 步骤S309:对初始检索结果进行一致性校验和置信度聚合,得到查询信息的目标检索结果。

[0105] 实际应用中,考虑到不同用户可能检索相同信息,如果能够对检索结果进行缓存的话,便可以借助预检索结果快速确定检索信息的目标检索结果,也即在基于系统提示词进行信息检索,得到查询信息的目标检索结果的过程中,可以获取缓存的预检索结果;检测系统提示词与预检索结果是否匹配;响应于系统提示词与预检索结果匹配,则从预检索结果中提取出查询信息的目标检索结果;响应于系统提示词与预检索结果不匹配,则可以对系统提示词进行全量检索,得到相应的目标检索结果。在成本控制方面,预检索结果缓存机

中国知网 https://www.cnki.net

制可以显著减少重复计算成本,预计可降低计算成本50%以上,在节能方面,通过优化处理流程和减少无效计算,整体能耗可降低40%以上。

[0106] 在示例性实施例中,可以通过search_from_preindex()函数接收预检索结果的主题名称和子查询作为输入参数,在缓存的预检索结果中进行智能二次检索,以实现预检索功能。具体的,通过load_preindex_entries()函数加载缓存的预检索结果,通过resolve_preindex_base_dir()函数解析预检索结果中的预检索基础目录,通过slugify()函数将预检索结果中的主题名称转换为文件系统友好的格式,构建entries.json文件路径,加载预检索结果中的缓存条目数据,然后调用search_strict_in_entries()函数在缓存条目中执行智能检索,例如通过load_preindex_entries()函数加载预检索结果中的缓存条目,通过list_preindex_topics()函数列出可用的预检索主题,通过find_best_topic_for_query()函数为系统提示词找到最佳匹配的预检索主题,再通过resolve_topic_name()函数检测系统提示词是否命中预检索主题,当系统提示词命中预检索主题时,将预检索结果中的检索结果作为目标检索结果;当系统提示词未命中预检索主题时,自动回退到全量检索模式,确保检索结果的完整性,如图5所示。在此过程中,可以通过main()函数实现多级检索策略,以优先使用预检索结果进行检索,当缓存未命中时自动切换到全量检索模式进行检索。

[0107] 具体应用场景中,可以以“主题-子查询”二级索引组织预检索结果,在获取待处理的查询信息之后,直接基于查询信息进行预检索,在此过程中,主题索引将高频的检索结果映射到data/pre_index/主题/下的entries.json;子查询索引在查新信息命中主题后,对具体意图(如“唤醒阈值”、“CAN NM状态”)进行二次筛选,可以先在内存中完成严格匹配与证据对齐,仅对少量高纯度候选进入LLM裁决,当主题未命中或meta(元数据)质量低于阈值时,自动回退全量扁平化召回,再进入本申请之后的三维判定与批量流程,如图6所示。

[0108] 在示例性实施例中,在进行全量检索的过程中,可以按照统一的语义模板对系统提示词进行对齐和约束,得到明确以“是/否”为结论的语义处理结果,语义模板可以为三维语义模板,比如在汽车行业,可以以功能为唤醒/启停/防误触,领域为车身控制/网络管理/开关系统,场景为驻车/上电/休眠边界条件等构建三维语义模板,约束可以为根据专家提示词进行约束,以将判断统一到同一语义坐标系获得高一致性;调用训练好的大语言模型对语义处理结果进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果,以借助温度系数来保证大语言模型的稳定输出,以借助最大令牌数对初始检索结果的数据量进行限制,其中温度系数可以为低温度系数,最大令牌数可以为1024等;对初始检索结果进行一致性校验和置信度聚合,得到查询信息的目标检索结果,比如仅当同一系统提示词的机制证据充分且裁决一致时,才将初始检索结果作为查询信息的目标检索结果等,且具体应用场景中,大语言模型输出的目标检索结果可以为由是和否组成的判断结果,并且可以转换为布尔值列表返回给调用方,如图7所示,以供调用方处理后展示给用户。

[0109] 为了便于理解本申请提供的信息检索方案,现假设对汽车行业进行检索,采用手段和效果如表1所示,则可以包括以下步骤:

[0110] 获取用户输入的与车辆相关的查询信息,可以为新项目需求分析、需求变更影响评估、需求一致性检查、方案设计等;

[0111] 确定与查询信息匹配的核心判断标准和排除规则;核心判断标准包括功能匹配标

中国知网 https://www.cnki.net

准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历史版本排除规则;

[0112] 生成查询信息的上下文信息;

[0113] 对查询信息中的段落进行去噪、空白规范、断行合并、列表合并、单位标准化和术语标准化,得到自然段处理结果;

[0114] 对查询信息中的表格和图片进行表头键值化和文本提取,得到结构化占位条目和位置指针;

[0115] 按照语义边界,将查询信息中跨段落的语句切分为最小语义单元,生成最小语义单元与对应段落间的父子关系和顺序索引;

[0116] 将自然段处理结果、结构化占位条目、位置指针、最小语义单元、父子关系和顺序索引,作为初始信息;

[0117] 对初始信息进行证据抽取和索引增强,得到候选信息;

[0118] 对候选信息进行特征提取,得到特征数据;

[0119] 对特征数据进行去重与弱相似合并,得到原子条目;

[0120] 基于上下文信息,生成原子条目的元数据,元数据包括源文件、段落定位结果、主题候选结果、证据片段摘要、长度和质量评分;

[0121] 对原子条目进行分组,得到条目分组结果;

[0122] 按照核心判断标准和排除规则,批量对条目分组结果进行处理,得到系统提示词;

[0123] 获取缓存的预检索结果;

[0124] 检测系统提示词与预检索结果是否匹配;

[0125] 响应于系统提示词与预检索结果匹配,则从预检索结果中提取出查询信息的目标检索结果;

[0126] 响应于系统提示词与预检索结果不匹配,则按照统一的语义坐标系对系统提示词进行对齐和约束,得到语义模板;

[0127] 调用训练好的大语言模型对语义模板进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果;

[0128] 对初始检索结果进行一致性校验和置信度聚合,得到查询信息的目标检索结果。

[0129] 表1 本方案实现手段及效果

中国知网 https://www.cnki.net

[0130]

序号	核心改进点	具体技术手段	主要技术效果
1	大语言模型智能相关性判断	角色定位“汽车系统需求分析专家”；专业化提示词（判断标准+排除规则）；结构化输出	检索精度显著提升；误报率大幅下降；深度语义理解，过滤无关条目
2	批量处理优化机制	可配置批次大小；循环分批；批量LLM调用；结果整合	API调用次数大幅减少；处理时间显著缩短；支持大规模数据高效处理
3	预检索缓存系统	主题化缓存目录；主题匹配；缓存加载；质量阈值控制	缓存命中时速度成倍提升；计算资源消耗降低；未命中自动回退全量，保证完整性
4	多级检索策略	缓存优先→未命中自动切换全量；条件判断逻辑；结果整合	精度与效率平衡；用户无感切换；始终输出最佳检索结果
5	专业化提示词结构	角色专家化；多维度判断标准；多项排除规则；结构化模板	领域适应性增强；汽车术语理解准确；一致性输出；可解释性强

[0131] 将本申请与现有方案对比后，结果如表2所示；对本申请方案进行测试验证后，测试验证包括：功能测试、性能测试、稳定性测试、兼容性测试等，测试结果表明，本申请方案在准确性、效率、稳定性等方面都达到了预期目标，具有实际应用价值。

[0132] 表2 本申请与已有方案比较表

中国知网 https://www.cnki.net

[0133]

序号	核心技术痛点（现有技术缺陷）	本申请采用的技术手段（关键词）	主要技术效果（定量/定性）
1	无法准确理解用户查询的真实意图，导致结果偏差大	引入大语言模型深度语义理解；角色设定为“汽车系统需求分析专家”	检索准确率由 60-70%提升至 90%以上；人工二次筛选工作量显著减少
2	误报/漏报严重，检索精度低（关键词或向量匹配局限）	LLM 智能相关性判断：3 项核心标准+5 条严格排除规则	精度由 65%→92%+；误报率由35%→8%以下；结果质量与可信度大幅提升
3	难以处理专业领域复杂术语、概念（如 E_CSW、CAN 唤醒）	专业化提示词设计+领域知识注入+角色专家化	准确理解汽车电子术语及隐含技术关系；同一功能不同表述被统一识别
4	大规模数据处理效率低，难支持企业级应用	批量 LLM 调用（可配置 BATCH_SIZE=10）+预检索缓存机制	API 调用次数减少 80%+；处理效率提升 3-5 倍；计算成本降低 50%+；能耗降低 40%+
5	缺乏深度智能判断与可解释性，无法复杂推理	结构化提示词+多维度判断（功能/领域/上下文）+逐条输出“是/否”	实现多层次语义推理；结果附带判断依据，可解释、可验证、可追溯

[0134] 请参阅图8,图8为本申请实施例提供的一种信息检索系统的结构示意图。

[0135] 本申请实施例提供的一种信息检索系统,可以包括:

[0136] 查询信息获取模块101,用于获取待处理的查询信息;

[0137] 筛选条件确定模块102,用于确定与查询信息匹配的核心判断标准和排除规则;

[0138] 查询处理模块103,用于按照核心判断标准和排除规则,对查询信息进行处理,得到系统提示词;

[0139] 检索模块104,用于基于系统提示词进行信息检索,得到查询信息的目标检索结果;

[0140] 其中,核心判断标准包括功能匹配标准、领域一致标准和上下文相关标准;排除规则包括通用描述排除规则、系统边界排除规则、词汇重叠排除规则、间接相关排除规则和历

中国知网 https://www.cnki.net

史版本排除规则。

[0141] 本申请实施例提供的一种信息检索系统,查询处理模块可以包括:

[0142] 扁平化单元,用于对查询信息进行扁平化处理,得到查询信息对应的原子条目;

[0143] 分组单元,用于对原子条目进行分组,得到条目分组结果;

[0144] 处理单元,用于按照核心判断标准和排除规则,批量对条目分组结果进行处理,得到系统提示词。

[0145] 本申请实施例提供的一种信息检索系统,扁平化单元用于:生成查询信息的上下文信息;对查询信息进行处理,得到初始信息;对初始信息进行证据抽取和索引增强,得到候选信息;对候选信息进行特征提取,得到特征数据;对特征数据进行去重与弱相似合并,得到原子条目;基于上下文信息,生成原子条目的元数据。

[0146] 本申请实施例提供的一种信息检索系统,扁平化单元用于:对查询信息中的段落进行去噪、空白规范、断行合并、列表合并、单位标准化和术语标准化,得到自然段处理结果;对查询信息中的表格和图片进行表头键值化和文本提取,得到结构化占位条目和位置指针;按照语义边界,将查询信息中跨段落的语句切分为最小语义单元,生成最小语义单元与对应段落间的父子关系和顺序索引;将自然段处理结果、结构化占位条目、位置指针、最小语义单元、父子关系和顺序索引,作为初始信息。

[0147] 本申请实施例提供的一种信息检索系统,扁平化单元用于:基于上下文信息,生成原子条目的元数据,元数据包括源文件、段落定位结果、主题候选结果、证据片段摘要、长度和质量评分。

[0148] 本申请实施例提供的一种信息检索系统,检索模块可以包括:

[0149] 预检索结果获取单元,用于获取缓存的预检索结果;

[0150] 检测单元,用于检测系统提示词与预检索结果是否匹配;

[0151] 预检索单元,用于响应于系统提示词与预检索结果匹配,则从预检索结果中提取出查询信息的目标检索结果。

[0152] 本申请实施例提供的一种信息检索系统,还可以包括:

[0153] 全量检索单元,用于检测单元检测系统提示词与预检索结果是否匹配之后,响应于系统提示词与预检索结果不匹配,则按照统一的语义坐标系对系统提示词进行对齐和约束,得到语义模板;调用训练好的大语言模型对语义模板进行检索,得到值为温度系数且数量与最大令牌数匹配的初始检索结果;对初始检索结果进行一致性校验和置信度聚合,得到查询信息的目标检索结果。

[0154] 本申请还提供了一种电子设备及计算机可读存储介质,其均具有本申请实施例提供的一种信息检索方法具有的对应效果。请参阅图9,图9为本申请实施例提供的一种电子设备的结构示意图。

[0155] 本申请实施例提供的一种电子设备,包括存储器201和处理器202,存储器201中存储有计算机程序,处理器202执行计算机程序时实现如上任一实施例所描述信息检索方法的步骤。

[0156] 请参阅图10,本申请实施例提供的另一种电子设备中还可以包括:与处理器202连接的输入端口203,用于传输外界输入的命令至处理器202;与处理器202连接的显示单元204,用于显示处理器202的处理结果至外界;与处理器202连接的通信模块205,用于实现电

中国知网 https://www.cnki.net

子设备与外界的通信。显示单元204可以为显示面板、激光扫描式显示器等;通信模块205所采用的通信方式包括但不局限于移动高清链接技术(Mobile High-Definition Link,MHL)、通用串行总线(Universal Serial Bus,USB)、高清多媒体接口(High—Definition Multimedia Interface,HDMI)、无线连接:无线保真技术(Wireless Fidelity,WiFi)、蓝牙通信技术、低功耗蓝牙通信技术、基于IEEE802.11s的通信技术。

[0157] 本申请实施例提供的一种计算机可读存储介质,计算机可读存储介质中存储有计算机程序,计算机程序被处理器执行时实现如上任一实施例所描述信息检索方法的步骤。

[0158] 本申请所涉及的计算机可读存储介质包括随机存储器(Random Access Memory,RAM)、内存、只读存储器(Read-Only Memory,ROM)、电可编程ROM、电可擦除可编程ROM、寄存器、硬盘、可移动磁盘、CD-ROM(Compact Disc Read-Only Memory,只读光盘)、或技术领域内所公知的任意其它形式的存储介质。

[0159] 本申请实施例提供的一种计算机程序产品,包括计算机程序/指令,该计算机程序/指令被处理器执行时实现如上任一实施例所描述信息检索方法的步骤。

[0160] 本申请的技术实现可以基于Python编程语言,采用模块化设计架构。核心代码文件为function_search_agent.py,包含714行代码,主要实现基于大语言模型的智能相关性判断功能。代码结构清晰,包含llm_relevance_judgment()、search_and_print()、search_from_preindex()等核心函数,每个函数都有明确的输入输出参数和功能说明。以汽车为例,代码实现中使用了专业的汽车系统需求分析术语,如“E_CSW”、“Park Switch”、“唤醒机制”等,体现了本方案在汽车行业的专业应用背景。代码注释详细,包含函数功能说明、参数解释、返回值说明等,便于用户理解技术实现细节。

[0161] 本申请可以采用YAML配置文件进行参数管理,配置文件为settings.yaml,包含API提供商配置、模型参数设置、文件路径配置等关键信息。系统支持OpenAI和LiteLLM两种API提供商,通过配置参数实现灵活的API切换。关键配置参数包括:BATCH_SIZE=10(批量处理大小)、temperature=0.1(LLM输出随机性控制)、max_tokens=1024(输出长度限制)、debug_mode=false(调试模式控制)等。这些参数设置直接影响系统的性能表现和检索效果,是方案的组成部分。

[0162] 本申请处理的数据格式可以为JSON结构,包含ID、REQ_ID、TEXT、IMG_URL、TABLE等字段。数据来源为汽车行业的需求文档,如OEM_REQ.json等文件,包含大量的汽车电子系统需求信息。预检索结果缓存可以采用主题化存储结构,每个主题对应一个目录,包含meta.json(元数据)和entries.json(缓存条目)两个文件。缓存目录结构为data/pre_index/主题名称/,便于主题管理和缓存维护。

[0163] 此外,本申请方案具有良好的可扩展性,支持通过配置参数调整系统行为,支持添加新的API提供商和模型类型。代码采用模块化设计,各功能模块相对独立,便于功能扩展和维护。系统支持详细的日志记录和调试信息输出,便于问题诊断和性能优化。通过配置文件管理,系统可以适应不同的部署环境和性能要求。

[0164] 本申请实施例提供的一种信息检索系统、电子设备及计算机可读存储介质中相关部分的说明请参见本申请实施例提供的一种信息检索方法中对应部分的详细说明,在此不再赘述。另外,本申请实施例提供的上述技术方案中与现有技术中对应技术方案实现原理一致的部分并未详细说明,以免过多赘述。

中国知网 https://www.cnki.net

[0165] 还需要说明的是,在本文中,诸如第一和第二等之类的关系术语仅仅用来将一个实体或者操作与另一个实体或操作区分开来,而不一定要求或者暗示这些实体或操作之间存在任何这种实际的关系或者顺序。而且,术语“包括”、“包含”或者其任何其他变体意在涵盖非排他性的包含,从而使得包括一系列要素的过程、方法、物品或者设备不仅包括那些要素,而且还包括没有明确列出的其他要素,或者是还包括为这种过程、方法、物品或者设备所固有的要素。在没有更多限制的情况下,由语句“包括一个……”限定的要素,并不排除在包括所述要素的过程、方法、物品或者设备中还存在另外的相同要素。

[0166] 对所公开的实施例的上述说明,使本领域技术人员能够实现或使用本申请。对这些实施例的多种修改对本领域技术人员来说将是显而易见的,本文中所定义的一般原理可以在不脱离本申请的精神或范围的情况下,在其它实施例中实现。因此,本申请将不会被限制于本文所示的这些实施例,而是要符合与本文所公开的原理和新颖特点相一致的最宽的范围。

中国知网 https://www.cnki.net

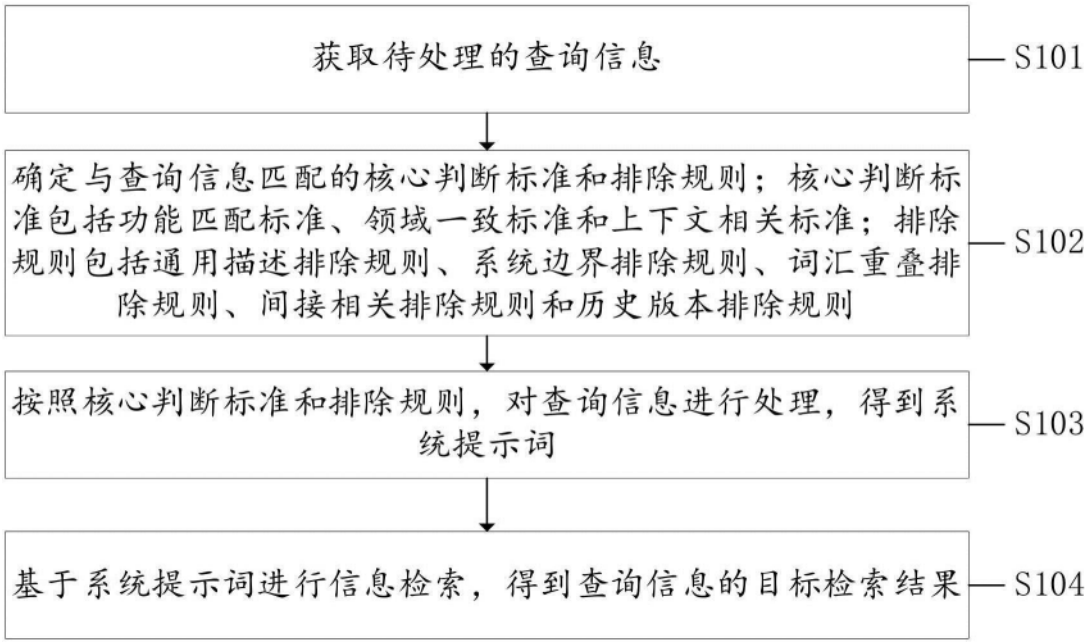


图 1

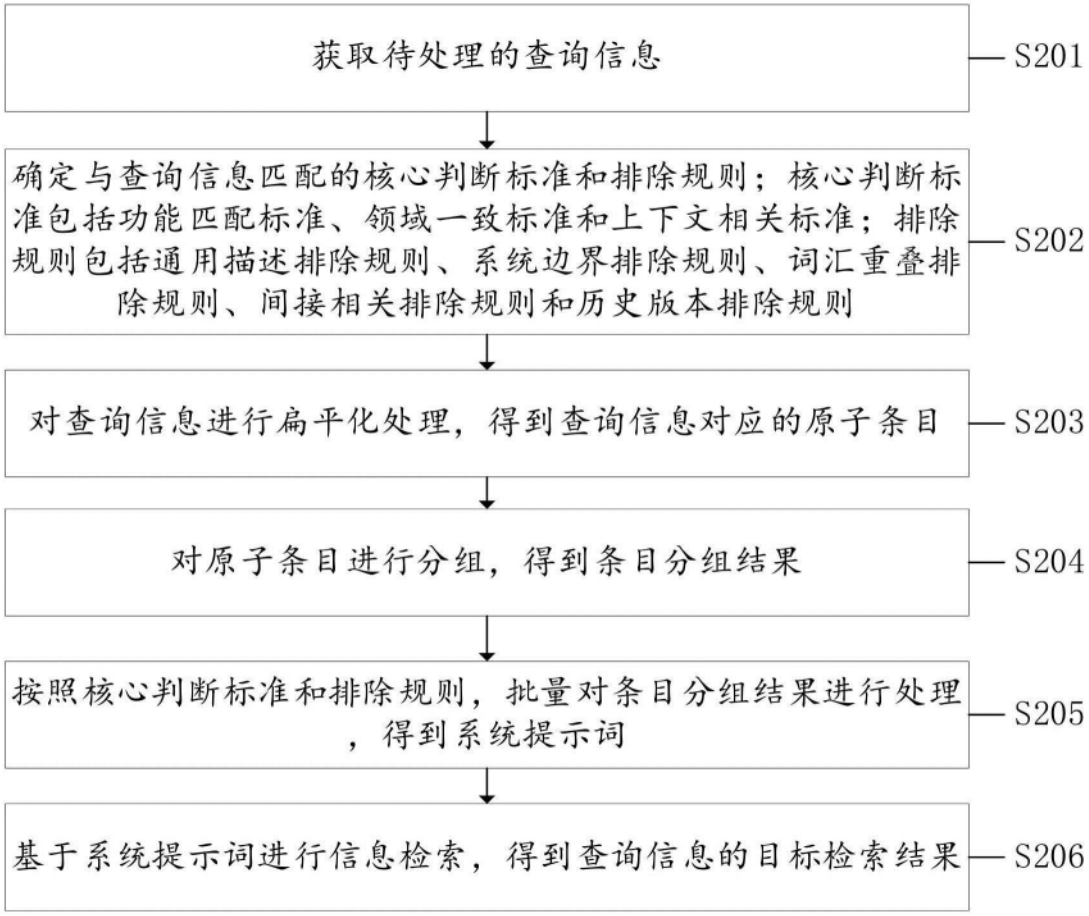


图 2

中国知网 https://www.cnki.net

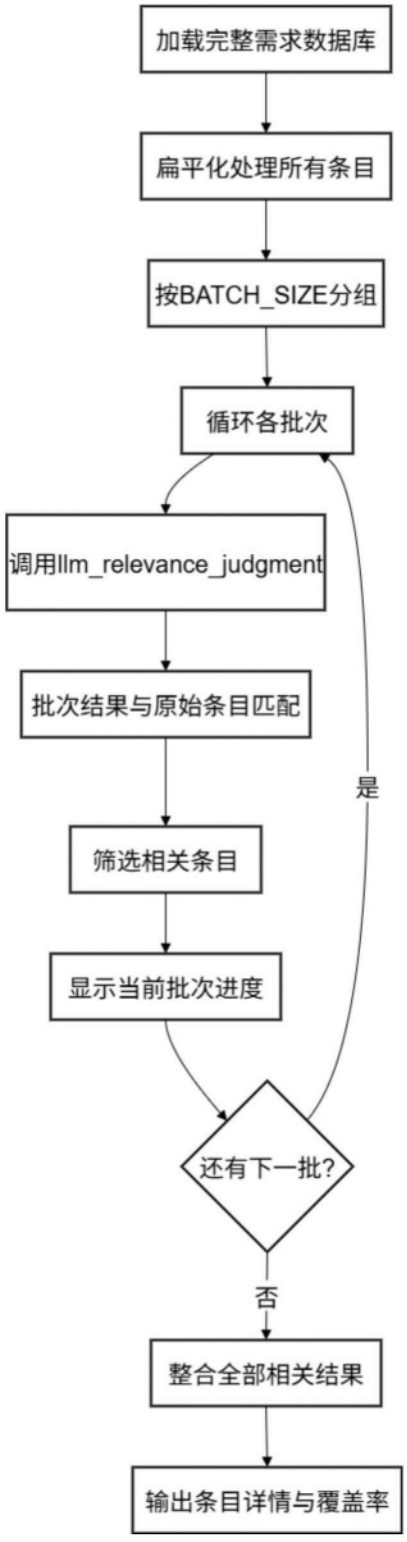


图 3

中国知网 https://www.cnki.net

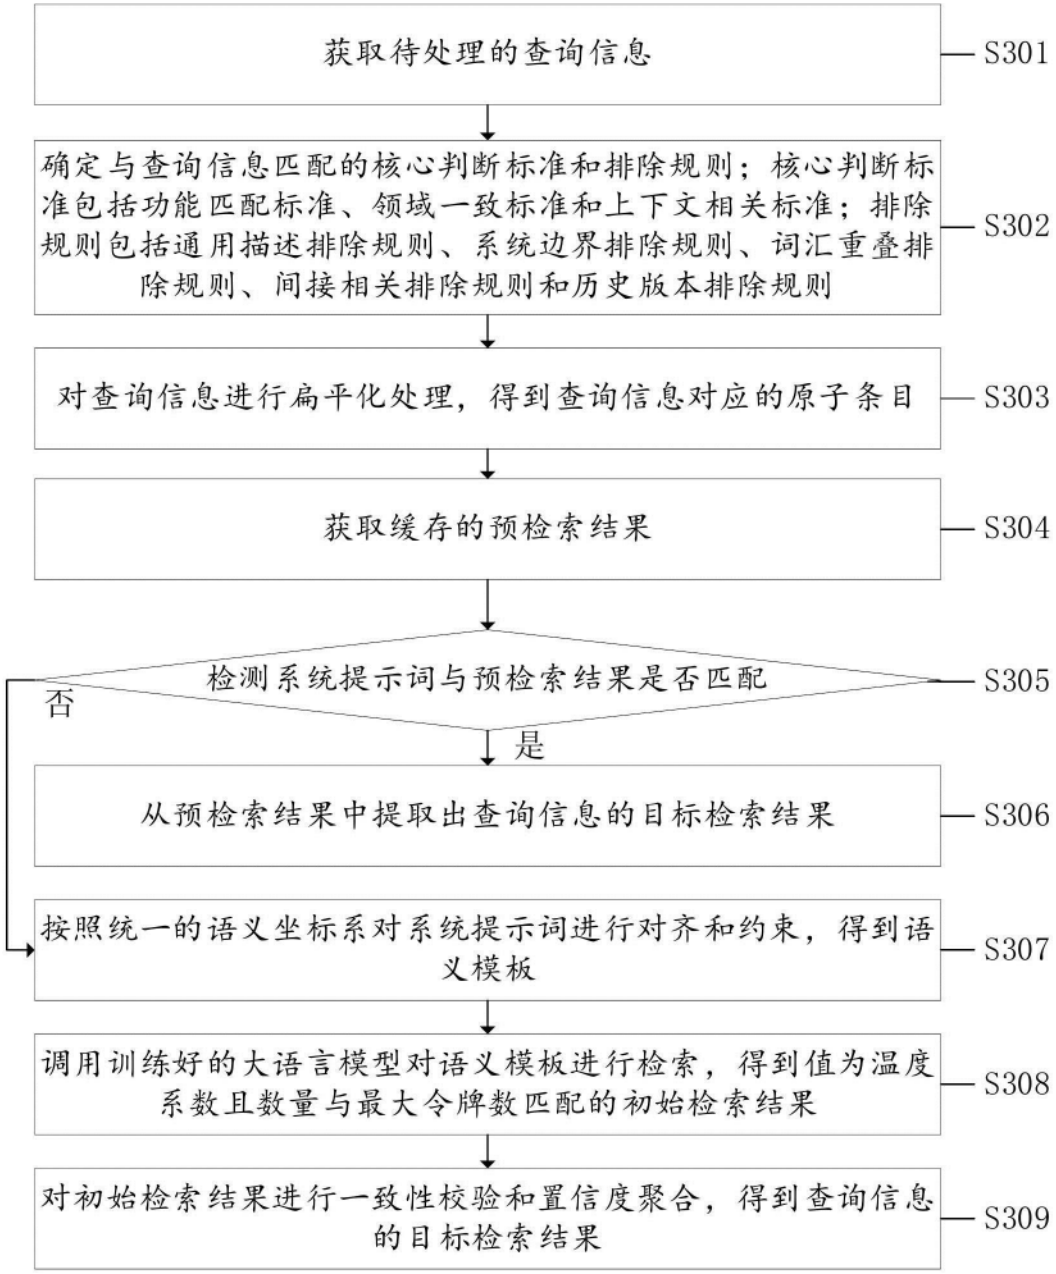


图 4

中国知网 https://www.cnki.net

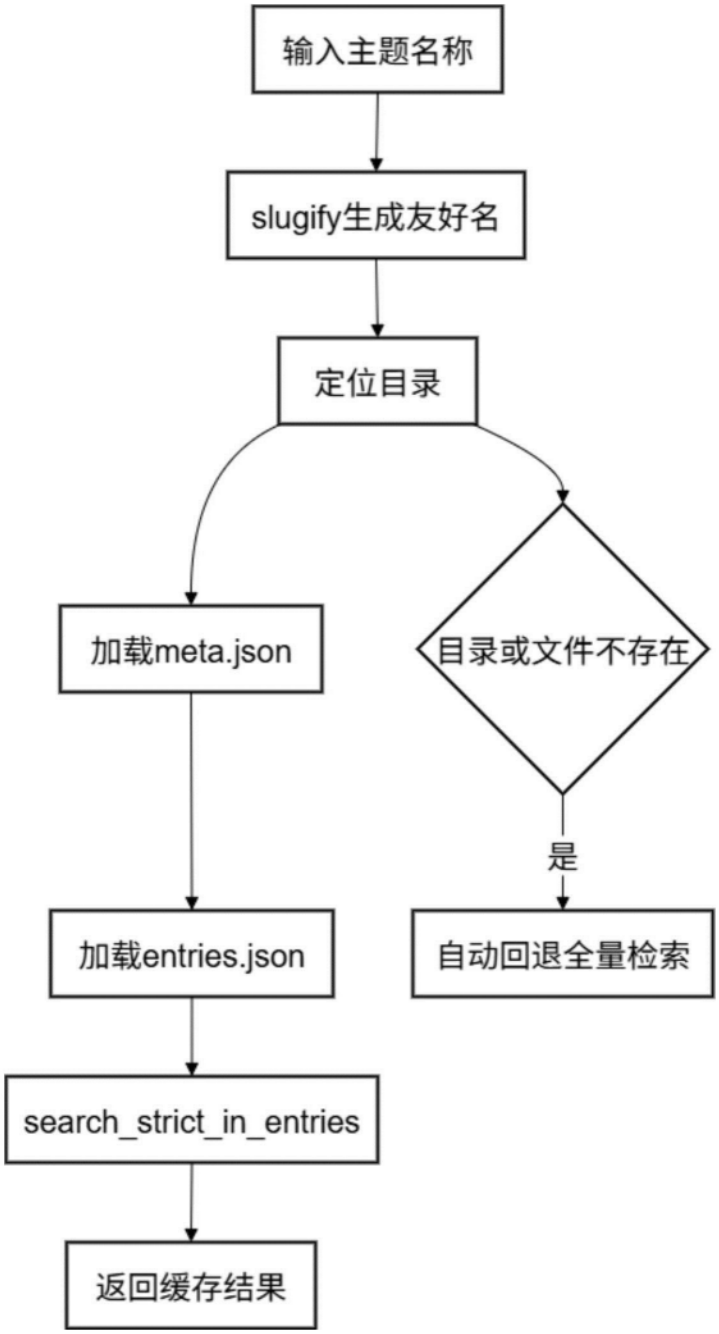


图 5

中国知网 https://www.cnki.net

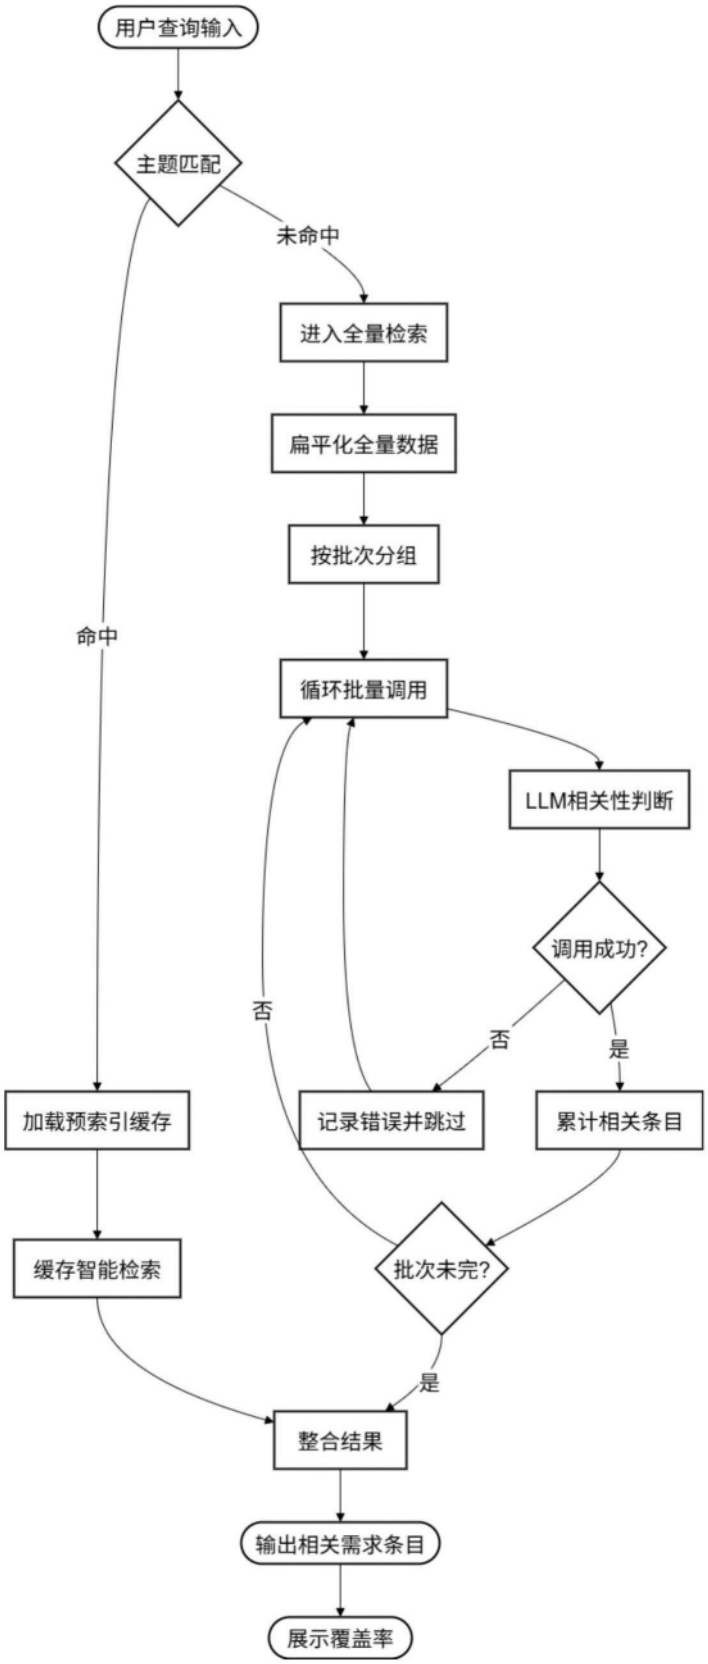


图 6

中国知网 https://www.cnki.net

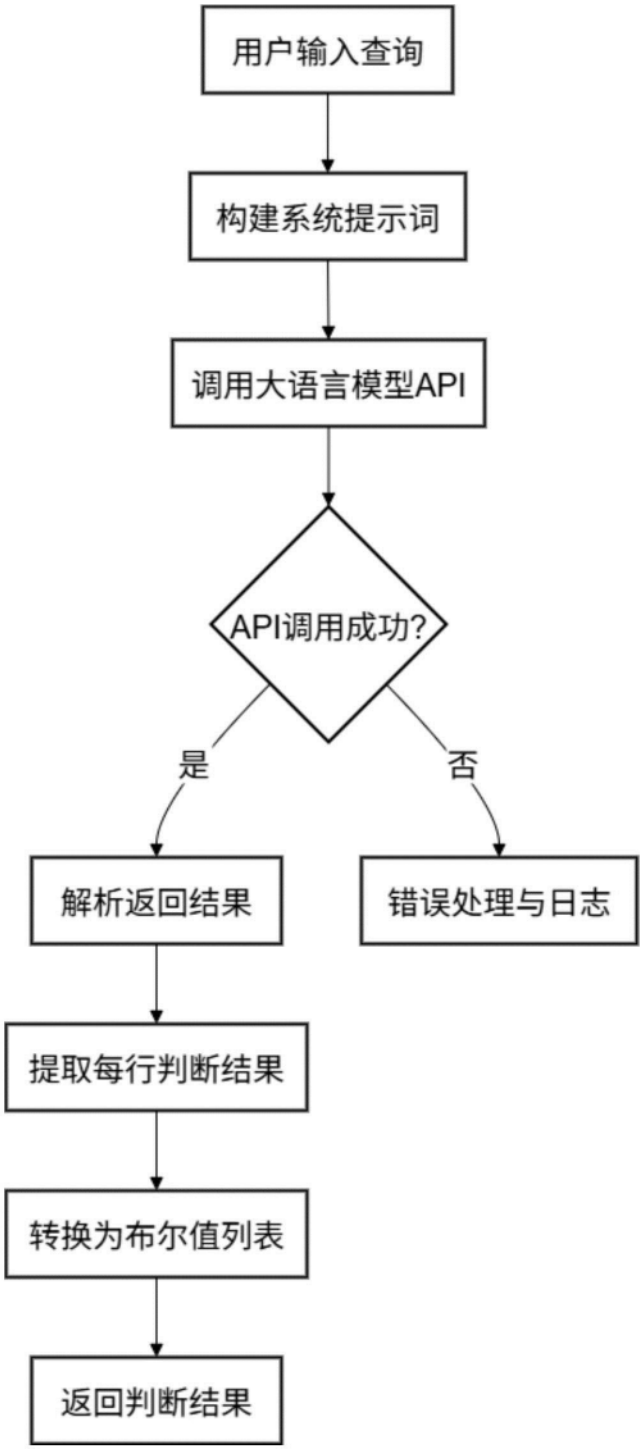


图 7

中国知网 https://www.cnki.net

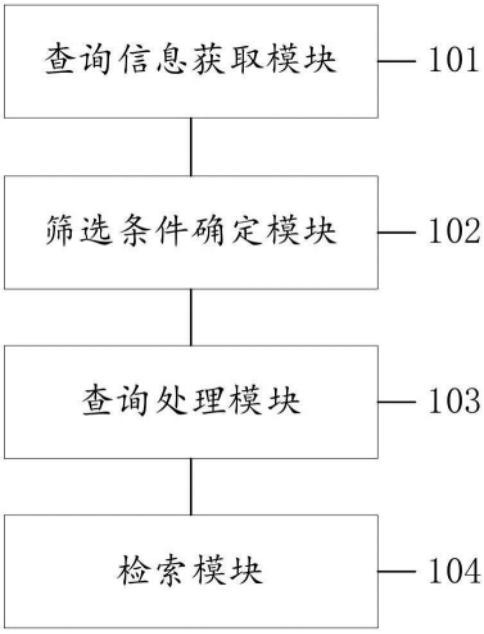


图 8

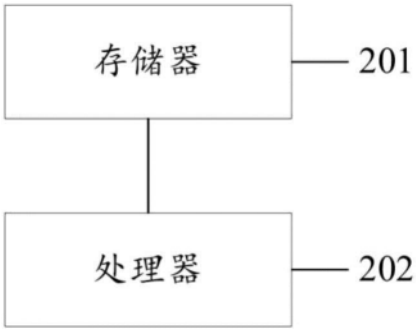


图 9

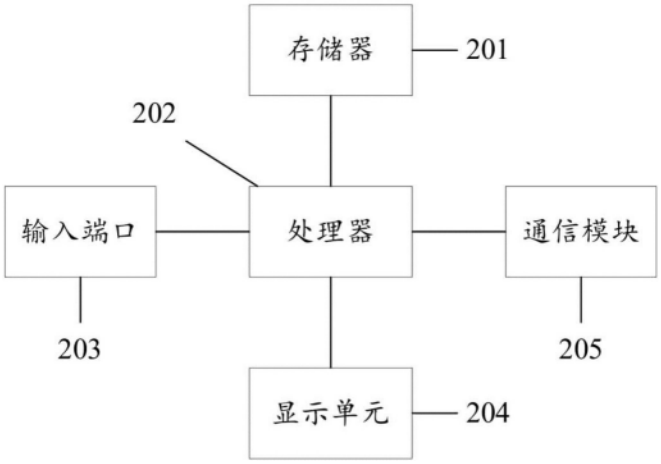


图 10

中国知网 https://www.cnki.net